


# Análise de notícias das Olimpíadas

---



**Fonte: *exame*.**



# Análise de notícias das Olimpíadas

Fonte: **exame.**

## Sumário

### 01. Base de dados

### 02. Processamento (PLN)

1. Limpeza
2. Remoção Stopwords
3. Bag of Words
4. TF-IDF

### 03. t-SNE

### 04. Classificação com Random Forest



# Dados

333

notícias coletadas

exame.

Fonte das notícias

Olimpíadas

Filtro aplicado na busca

## Colunas disponíveis na base:

url

Link de origem da notícia

titulo

Título completo da notícia

texto

Texto da notícia

tags

Categorias (apenas 8 de 333 preenchidas)



# Nuvem de palavras





# Processamento de Linguagem Natural (PLN)

Processamento de Linguagem Natural, é uma área da ciência de dados que estuda como transformar textos em informação estruturada. Com essas técnicas, conseguimos analisar notícias, identificar temas, contar palavras, comparar documentos e preparar dados textuais para modelos de aprendizado de máquina.

**1 Limpeza Básica**

**2 Remoção Stopwords**

**3 Bag of Words**

**4 TF-IDF**



# 1. Limpeza básica

|                                   |                                                |
|-----------------------------------|------------------------------------------------|
| <code>wordpunct_tokenize</code>   | separa o texto em palavras e pontuacao.        |
| <code>texto.lower()</code>        | coloca tudo em minusculas.                     |
| <code>unidecode(texto)</code>     | troca letras acentuadas por letras sem acento. |
| <code>token.isalnum()</code>      | mantem apenas letras e numeros.                |
| <code>" ".join(tokens)</code>     | junta os tokens em uma frase limpa.            |
| <code>.apply(limpar_texto)</code> | aplica a funcao em todas as noticias.          |

Exemplo:

Entrada: “Brasil é Ouro em Paris 2024!”

Saída: “brasil e ouro em paris 2024”



## 2. Removendo stopwords

Stopwords são palavras muito comuns que aparecem frequentemente, mas geralmente ajudam pouco a entender o tema de um texto. Removê-las reduz o ruído e melhora a qualidade das análises

### Exemplos de Stopwords

a o de da para  
que com quem  
em se por é  
na do ao  
uma das ou  
mas do

### Antes e depois

ANTES

“brasil e ouro em paris 2024”

↓ Remover\_stopwords()

DEPOIS

[“brasil”, “ouro”, “paris”, “2024”]



### 3. Bag of Words (Bow)

Cada linha representa uma notícia e cada coluna representa uma palavra do vocabulário. O valor indica quantas vezes aquela palavra aparece na notícia. A ordem das palavras é ignorada.

Exemplo de matriz BoW

| Notícia   | brasil | ouro | paris |
|-----------|--------|------|-------|
| Notícia 1 | 2      | 1    | 1     |
| Notícia 2 | 1      | 0    | 2     |
| Notícia 3 | 3      | 2    | 1     |


A partir da tabela ao lado, podemos analisar as frequências das palavras e as palavras únicas

(foi retirada as colunas que possuem números)





# Resultados – Análise de Frequência (Bow)





## 4. TF-IDF

É uma forma de dar peso para as palavras tentando responder a duas perguntas ao mesmo tempo:

- 1 Esta palavra aparece bastante nesta notícia?
- 2 Esta palavra é rara no conjunto de notícias?

$$TF(t, d) = \frac{\text{quantidade do termo } t \text{ no documento } d}{\text{total de termos no documento } d}$$


TF significa frequência do termo



## 4. TF-IDF

Notícia analisada (índice 325):

*“Gabriel Medina conquista o bronze nas Olimpíadas de Paris”*



**medina:** personagem central, raro nas demais notícias

**olimpíadas:** nem todas as notícias usam essa palavra

**ondas:** técnico do surfe, específico aqui

**medalhas:** aparece em outras notícias

**robinson:** adversário australiano

**notas:** pontuação do surfe


**teahupo:** local da prova

# 5. t-SNE — Comparação BoW vs TF-IDF


exame.

Visualização t-SNE: agrupamento de 333 notícias olímpicas  
(perplexity=10, cada ponto = uma notícia)

Bag of Words — t-SNE



TF-IDF — t-SNE



## Padrões identificados nos clusters

### Resultados e competição

**BoW:** Surfe, ginástica, patinação — cobertura ao vivo de provas

**TF-IDF:** Mais coeso: nomes de atletas e esportes têm peso alto

### Perfis humanos e bastidores

**BoW:** Histórias de atletas, vida na vila olímpica

**TF-IDF:** Separação mais clara: vocabulário narrativo distinto. Pódio dos atletas

### Cerimônia e Olimpíadas de Inverno

**BoW:** Misturado com outros temas no BoW

**TF-IDF:** Cluster mais definido: "sena", "abertura", "barco" têm IDF alto

### Historias

**BoW:** Como vai limpar o rio Sena?; Uniforme dos atletas.

**TF-IDF:** Agrupamento similar, mas mais separado no espaço

💡 **Conclusão:** O TF-IDF produziu clusters mais coesos. Palavras como "sena", "barco" e "abertura" têm IDF alto e diferenciam bem o grupo de Cerimônia. No BoW essas palavras competiam com "paris" e "brasil", dificultando a separação.



# Classificação de Notícias Utilizando Random Forest

**Objetivo:** Desenvolver um modelo de classificação de textos capaz de identificar notícias relacionadas ao esporte utilizando técnicas de Machine Learning.

## Objetivos específicos

- Usar a base TF-IDF;
- Aplicar o algoritmo Random Forest;
- Utilizar o OOB Score para calibração do modelo;
- Avaliar o desempenho utilizando métricas de classificação;

## Variável resposta binária

$$Y = \begin{cases} 0, & \text{notícias sem a palavra 'esporte'} \\ 1, & \text{notícias com a palavra 'esporte'} \end{cases}$$



# Random Forest

- Cada árvore é treinada com uma amostra bootstrap dos dados;
- Algumas observações ficam fora do treinamento;
- Essas observações formam o OOB (Out-Of-Bag);
- O OOB permite estimar o desempenho do modelo.

## Principais vantagens

- boa capacidade preditiva;
- redução de overfitting;
- funciona bem com muitas variáveis;
- calcula a importância das variáveis.

No projeto, a Random Forest foi utilizada para classificar notícias relacionadas ao esporte a partir das palavras obtidas pelo TF-IDF.

## As observações OOB funcionam como validação interna:

- a árvore faz previsões apenas nos dados que ficaram fora do bootstrap;
- o modelo compara as previsões com os valores reais;
- assim é calculado o OOB Score.



# OOB Score na Prática — Calibração do Número de Árvores

O OOB Score é usado para escolher o melhor valor de `n_estimators` (número de árvores) sem usar o conjunto de teste — garantindo uma avaliação final justa.

## Código de calibração:

```
opcoes_arvores = [10, 50, 100, 200, 300, 500]

for n in opcoes_arvores:
    modelo = RandomForestClassifier(
        n_estimators=n,
        oob_score=True,    # ativa o OOB
        random_state=42,
        n_jobs=-1
    )
    modelo.fit(X_treino, y_treino)
    oob = modelo.oob_score_    # acurácia OOB

# Escolhe o melhor n_estimators
melhor_n = df_oob.loc[
    df_oob["oob_score"].idxmax(),
    "n_estimators"]
```

## `oob_score=True`

Parâmetro que ativa o cálculo do OOB no scikit-learn. Sem ele, o atributo `oob_score_` não é gerado.

## `modelo.oob_score_`

Após o `.fit()`, este atributo contém a acurácia estimada pelo OOB — sem usar o conjunto de teste.

## Escolha pelo maior OOB

O `n_estimators` com maior OOB Score é selecionado para o modelo final.



# Divisão dos Dados: Treino e Teste

Com o OOB Score, não precisamos de um conjunto de validação separado. A divisão é apenas Treino (80%) e Teste (20%), com  $n = 333$  notícias.

**Divisão dos dados ( $n = 333$ ):**

**TREINO — 266 notícias (80%)**

**TESTE  
67 (20%)**

**Por que só dois conjuntos?**

**Sem OOB — abordagem tradicional:**

- Precisaria de 3 conjuntos: Treino (60%) + Validação (20%) + Teste (20%)
- Com  $n=333$ , sacrifica mais dados de treino
- Estimativa menos estável com poucos dados

**Com OOB — abordagem do notebook:**

- Apenas 2 conjuntos: Treino (80%) + Teste (20%)
- O OOB faz o papel da validação internamente
- Mais dados para treino → modelo mais robusto





# Matriz de Confusão — Resultados e Interpretação

**Matriz de Confusão:** mostra detalhadamente os acertos e erros do modelo por categoria.

## Valores obtidos no teste:

|                      | Previsto:<br>Sem esporte                      | Previsto:<br>Com esporte                      |
|----------------------|-----------------------------------------------|-----------------------------------------------|
| Real:<br>Sem esporte | <b>VN</b><br><b>34</b><br>Verdadeiro Negativo | <b>FP</b><br><b>2</b><br>Falso Positivo       |
| Real:<br>Com esporte | <b>FN</b><br><b>6</b><br>Falso Negativo       | <b>VP</b><br><b>25</b><br>Verdadeiro Positivo |

## Interpretações:

|                |                                                                                                                       |
|----------------|-----------------------------------------------------------------------------------------------------------------------|
| <b>VP (25)</b> | O modelo identificou corretamente 25 notícias de esporte. São os acertos mais importantes para o objetivo do projeto. |
| <b>VN (34)</b> | O modelo identificou corretamente 34 notícias que não eram de esporte.                                                |
| <b>FN (6)</b>  | 6 notícias de esporte foram classificadas como "não esporte" — o modelo deixou passar.                                |
| <b>FP (2)</b>  | 2 notícias que não eram de esporte foram classificadas como esporte — falso alarme.                                   |



# Métricas de Avaliação — Resultados

Os resultados abaixo foram obtidos no conjunto de teste (67 notícias) após o modelo ser treinado com 266 notícias e calibrado via OOB Score.

| Métrica                                                                                                                                                           | Fórmula                           | Resultado | Interpretação                                                                                     |
|-------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------|-----------|---------------------------------------------------------------------------------------------------|
| Acurácia                                                                                                                                                          | $(VP + VN) / Total$               | 88,1%     | O modelo acertou 59 das 67 previsões no conjunto de teste.                                        |
| Precisão                                                                                                                                                          | $VP / (VP + FP)$                  | 92,6%     | Quando o modelo disse que uma notícia era de esporte, acertou em 92,6% das vezes — alta precisão. |
| Recall                                                                                                                                                            | $VP / (VP + FN)$                  | 80,6%     | De todas as 31 notícias de esporte reais, o modelo encontrou 25 (80,6%).                          |
| F1-Score                                                                                                                                                          | $2 \times (P \times R) / (P + R)$ | 86,2%     | Média harmônica entre Precisão (92,6%) e Recall (80,6%) — desempenho equilibrado.                 |
| OOB Score obtido: 78,2% → OOB Score (78,2%) < Acurácia no Teste (88,1%): o modelo generalizou bem — o teste confirmou melhor desempenho que a estimativa interna. |                                   |           |                                                                                                   |



# Conclusão

## Processamento de Linguagem Natural

Limpeza, stopwords, BoW e TF-IDF transformaram 333 notícias em dados estruturados para análise.

## Visualização t-SNE

O TF-IDF gerou clusters mais coesos do que o BoW, separando melhor temas como cerimônias e esportes.

## Classificação Random Forest

Acurácia de 88,1%, Precisão de 92,6% e F1-Score de 86,2% — modelo eficaz para classificar notícias.

## Considerações Finais

- **PLN como base:** as técnicas de limpeza, remoção de stopwords e vetorização (BoW/TF-IDF) foram essenciais para preparar os textos.
- **TF-IDF superior ao BoW:** a ponderação por raridade gerou representações mais ricas, com clusters t-SNE mais coesos.
- **Random Forest eficiente:** com 88,1% de acurácia e calibração via OOB Score, o modelo classificou notícias de esporte com alto desempenho.
- **Generalização confirmada:** acurácia no teste (88,1%) superou o OOB Score (78,2%), indicando boa capacidade de generalização.

# OBRIGADA!



Fonte:  
**exame.**